

Rp 150 juta untuk 5.000 pelanggan: dibagi rata, atau dipusatkan?

Saya menyegmentasi 48.130 transaksi sebuah marketplace dengan SQL. Hasilnya, 8% pelanggan ternyata memegang 28,7% nilai transaksi, dan 857 pelanggan yang dulu rajin berhenti belanja hanya dalam satu kuartal. Dari situ, anggaran yang sama dipakai untuk membiayai dua program terukur, bukan voucher untuk semua orang.

Peran Data analyst **Data** Marketplace ritel, Jan 2025 – Mar 2026 **Tools** SQL, DuckDB, Python

Waktu 18 jam, September 2026

[Buka notebook analisis](#)

[Baca memo keputusan](#)

[Baca catatan keputusan](#)

Dataset dirancang meniru pola transaksi marketplace. Ini bukan data perusahaan sungguhan, dan tidak disajikan sebagai pengalaman kerja di perusahaan mana pun.

Ke mana Rp 150 juta pergi

Usulan pembagian anggaran retensi Q2 2026, menggantikan Rp 30.000 per orang bila dibagi rata ke 5.000 pelanggan.

- Rp 90 juta** Apresiasi dan akses prioritas untuk 400 Champions, Rp 225.000 per orang
- Rp 50 juta** Uji win-back pada 552 pelanggan yang baru berhenti: 276 dikirim, 276 pembeding
- Rp 10 juta** Cadangan pengukuran dan kanal, lintas program

Ringkasan

28,7%

nilai transaksi dipegang 400 pelanggan, 8% dari seluruhnya

857

dari 900 pelanggan At Risk masih rutin belanja tiga bulan sebelumnya

Rp 2,74 M

nilai historis kelompok yang sedang menghilang

48.130

transaksi bersih, dari 50.980 baris mentah

Anggaran retensi Rp 150 juta per kuartal selama ini dibagi rata ke 5.000 pelanggan, Rp 30.000 per orang, dan hasil kuartal lalu tidak memberi alasan untuk mengulanginya. Laporan ini memberi dasar untuk membaginya tidak rata.

Kalau diarahkan seluruhnya ke 400 pelanggan teratas, anggaran yang sama bernilai Rp 375.000 per orang.

Pembagian ini bisa dipertahankan bukan karena angkanya, melainkan karena tiga hal yang menyertainya: definisi data yang dinyatakan dan bisa diaudit tahap demi tahap, ambang segmen yang diuji kepekaannya, dan ukuran keberhasilan yang ditetapkan sebelum programnya jalan, lengkap dengan kelompok pembanding.

Konteks keputusan

Kuartal lalu promosi dikirim ke semua pelanggan, dengan open rate email 12% dan redemption voucher 3%. Keputusan yang menunggu laporan ini adalah pembagian anggaran Q2 2026. Keputusan itu diambil di awal April dengan data per 31 Maret, dan ditanggung satu orang: pemegang anggaran retensi, yang harus mempertahankannya di depan manajemen angka demi angka.

Kelompok pelanggan mana yang anggarannya dipusatkan, atas dasar apa, dan kenapa sebagian pelanggan sengaja tidak mendapat apa pun?

Yang dipertaruhkan lebih dari satu kuartal anggaran. Pembagian yang salah arah menghabiskan Rp 150 juta pada kelompok yang paling kecil sumbangannya, sementara kelompok yang menopang sebagian besar nilai transaksi terus diperlakukan sama seperti semua orang, kuartal demi kuartal, karena tidak pernah ada yang memeriksa bedanya.

Cara mengerjakan

Pekerjaan ini mengikuti enam langkah tetap. Tiga langkah pertama memakan waktu hampir sebanyak tiga langkah terakhir, dan itu disengaja.

1. Memahami situasi

Siapa yang memutuskan, kapan, dan apa yang dipertaruhkan

2. Menetapkan pertanyaan

Dari "berapa voucher" menjadi "kelompok mana, atas dasar apa"

3. Menguji kecukupan data

Profil kolom lebih dulu, lalu empat tahap pembersihan

4. Menjalankan analisis

Segmentasi RFM pada dua tanggal acuan, plus uji kepekaan

5. Gerbang bantahan

Temuan yang tidak lolos bantahannya sendiri tidak naik ke rekomendasi

6. Merumuskan rekomendasi

Lengkap dengan batas, syarat pembatal, dan ukuran keberhasilan

Tiga keputusan ditetapkan tertulis sebelum kueri analisis pertama dijalankan. Masing-masing punya pilihan yang sengaja saya tolak.

Keputusan	Yang dipilih	Yang ditolak, dan kenapa
Definisi transaksi	Baris unik bernilai positif sampai tanggal acuan	Memakai seluruh baris apa adanya. Duplikat menggelembungkan frekuensi, dan penjumlahan diam-diam melewati nilai kosong sementara pencacahan tetap menghitungnya, sehingga dua ukuran memakai dua definisi tanpa satu peringatan pun
Tanggal acuan dan jendela	Literal 2026-03-31, dengan riwayat dihitung dalam jendela tetap 15 bulan	Tanggal sistem, karena hasilnya berubah tiap hari. Riwayat kumulatif, karena tiap kuartal tambahan membuat ambang yang sama makin mudah dilewati
Garis antar-segmen	Ditetapkan sesudah membaca sebaran populasi, lalu diuji kepekaannya pada tujuh geseran	Skoring kuintil. Hasilnya searah, tetapi jauh lebih sulit dijelaskan ke pemegang anggaran

Data

Satu tabel transaksi berisi lima kolom dan 50.980 baris mentah, dari Januari 2025 sampai Maret 2026, ditambah 50 baris bertanggal sesudahnya. Tidak ada tabel pendamping. Pembersihan membuang 2.850 baris (5,6%) dalam empat tahap terpisah, dan jumlah tiap tahap tercatat.

Tahap	Yang dibuang	Dibuang	Sisa
Mentah			50.980
Dedup	Duplikat persis di kelima kolom	2.400	48.580
Nilai kosong	TotalValue NULL, pembayaran gagal	350	48.230
Nilai tak positif	Refund dan sampel gratis	50	48.180
Tanggal	Bertanggal sesudah tanggal acuan	50	48.130

Jumlah pelanggan unik tetap 5.000 di data mentah maupun bersih. Artinya baris yang dibuang milik pelanggan yang masih punya transaksi sah lainnya. Itu kebetulan yang menyenangkan di dataset ini, bukan jaminan, dan diperiksa ulang setiap kali pipeline dijalankan.

Yang *tidak* ada di data ikut menentukan klaim apa yang boleh dibuat. Tidak ada data hasil campaign, jadi tidak ada kolom yang menyatakan seseorang membeli karena voucher. Tidak ada biaya per kanal, jadi usulan pembagian berhenti di tingkat segmen. Tidak ada alasan pelanggan berhenti: pindah ke pesaing, kecewa pengiriman, dan sekadar tidak butuh lagi tampak identik di tabel ini. Karena itu laporan ini tidak memuat satu pun angka ROI atau proyeksi pemulihan.


Temuan

Tiga temuan, diurutkan menurut bobot keputusannya, bukan menurut urutan ditemukannya.

1. Nilai terkonsentrasi, tetapi lebih sedang daripada yang biasa diasumsikan

400 pelanggan (8,0%) memegang 28,7% nilai transaksi, atau 3,59 kali porsi seimbangannya, dengan median 22 transaksi dan Rp 8,06 juta per orang. Kelompok ini praktis sama dengan 400 pelanggan terbesar belanjanya: 399 dari 400 orang itu Champions. Yang tidak berlaku di sini justru aturan 80/20 yang biasa dipinjam, karena 20% pelanggan teratas memegang 49,2%, bukan 80%.

Seberapa terkonsentrasi nilainya, diadu dengan aturan 80/20



Apa yang tergambar

Pangsa nilai kumulatif terhadap pangsa pelanggan kumulatif, dalam persen, dengan 5.000 pelanggan diurutkan dari yang terbesar belanjanya.

Rentang data

48.130 transaksi bersih, dihitung per 2026-03-31.

Yang terlihat


Kurva menyimpang dari garis putus-putus jauh sebelum titik 8% ditandai, dan pada 20% pelanggan teratas ia mendarat di 49,2%.

Konsentrasi ini sifat sebaran datanya, bukan akibat garis segmen: kurvanya sudah menyimpang dari garis merata sebelum satu ambang pun ditarik.

2. Nilai yang sebanding sedang pergi, dan kelompoknya baru terbentuk

900 pelanggan (18,0%) bermedian 11 transaksi, bukti bahwa mereka pernah rutin, tetapi kini bermedian 112 hari tanpa transaksi. Kelompok ini membawa Rp 2,74 miliar nilai historis, atau 24,7% dari total. Ketika segmentasi yang sama dijalankan pada tanggal acuan tiga bulan lebih awal, 857 dari 900 orang itu masih tergolong rutin. Jadi ini kohort yang baru berhenti, bukan kolam lama yang mengendap.

Siapa yang dulu rajin, dan siapa yang memang tidak pernah terbiasa



Apa yang tergambar

Median hari sejak transaksi terakhir pada sumbu mendatar lawan median jumlah transaksi pada sumbu tegak, tiap segmen. Lingkaran yang lebih besar berarti segmen yang lebih banyak orangnya. Ukurannya sengaja diredam supaya bulatan besar tidak menelan bulatan lain, jadi bacalah sebagai perbandingan kasar; jumlah persisnya tertulis di tiap label.

Rentang data

5.000 pelanggan dari 48.130 transaksi bersih, dihitung per 2026-03-31.

Yang terlihat


Bulatan At Risk duduk jelas di kanan garis 90 hari dan bertahan di 11 transaksi.
Bulatan Lost duduk tepat di garis itu, di 5 transaksi.

Temuan ini bukan artefak panjang riwayat: dengan jendela 12 bulan di kedua tanggal, angkanya 850. Konteks kuartalannya sejalan. Pelanggan aktif bertahan di sekitar 3.950 selama empat kuartal, lalu turun ke 2.789 di Q1 2026. Kelompok ini hanya terlihat karena analisisnya dijalankan pada dua tanggal acuan; satu potret tidak bisa membedakan pelanggan yang memang begini dari pelanggan yang baru saja berubah.

3. Mayoritas pelanggan adalah pembeli ringan, bukan pelanggan setia yang hilang

2.600 pelanggan (52,0%) bermedian 5 transaksi dan Rp 0,67 juta. Mereka terbelah dua sama besar: 1.300 orang masih belanja dalam 90 hari terakhir, tetapi hanya 5 sampai 7 kali dalam 15 bulan, dan 1.300 orang sudah lebih lama tak terlihat dengan 2 sampai 4 transaksi.

Siapa yang porsinya lebih besar dari jumlahnya, dan siapa yang sebaliknya



Apa yang tergambar

Pangsa pelanggan dan pangsa nilai transaksi tiap segmen, dalam persen.

Rentang data

48.130 transaksi bersih dari 5.000 pelanggan, Januari 2025 sampai 2026-03-31, dihitung per 2026-03-31.

Yang terlihat

Arah selisihnya berbalik dari atas ke bawah. Di tiga baris teratas, batang biru melampaui batang abu; di baris terbawah, batang biru tinggal sekitar sepertiganya.

Keduanya profil kebiasaan yang tidak pernah terbentuk, bukan kebiasaan yang putus, sehingga label "Lost" terlalu keras untuk separuh pertamanya. Perbedaan inilah yang menjawab pertanyaan paling tajam di rapat: kenapa lebih dari separuh pelanggan sengaja tidak mendapat program kuartal ini.

Uji bantahan

Sebelum rekomendasi ditulis, setiap temuan saya serang dengan bantahan paling wajar yang bisa muncul di rapat. Untuk tiap bantahan ada tiga pertanyaan: penjelasan tandingan apa yang belum disingkirkan, data apa yang akan membatalkan temuannya, dan seberapa jauh asumsinya boleh digeser. Temuan yang tidak lolos lebih baik gugur di sini daripada di depan pemegang anggaran.

Bantahan atas temuan 1 Lolos

"8% memegang 28,7% itu artefak dari garis yang kamu tarik sendiri. Geser ambangnya, angkanya ikut."

Setengah benar. Angka 400 dan 28,7% memang bergantung pada ambang, tetapi bentuk sebarannya tidak. Monetary per pelanggan membentang dari Rp 44.457 sampai Rp 10,88 juta dengan median Rp 1,36 juta, dan kurva konsentrasi sudah menyimpang dari garis merata sebelum satu ambang pun ditarik. Di tujuh geseran ambang yang diuji, kelompok teratas tetap memegang 28,7% sampai 30,7% nilai.

Yang akan membatalkannya: sebaran Monetary yang datar, dengan nilai per pelanggan yang seragam. Data itu tidak ada di sini.

Bantahan atas temuan 2 Lolos

"857 itu artefak. Per Desember riwayatnya lebih pendek, wajar kalau segmennya bergeser."

Diperiksa langsung, bukan dinalar. Dengan panjang riwayat disamakan, 12 bulan di kedua tanggal, perpindahan Loyal ke At Risk tetap 850 orang. Untuk 857 orang versi resmi, Frequency dan Monetary-nya identik di kedua tanggal, karena mereka sama sekali tidak bertransaksi sesudah 2025-12-30. Perpindahan mereka murni perilaku.

Dari mana 900 pelanggan At Risk datang

Ke mana 5.000 pelanggan berpindah dalam satu kuartal

segmen per 2026-03-31

	Champions	Loyal	At Risk	Lost
Champions	83			
Loyal	305	1.060	857	
At Risk	11	40	43	132
Lost	1			2.468

segmen per 2025-12-31

Kotak amber: 857 dari 900 pelanggan At Risk hari ini masih Loyal tiga bulan sebelumnya.

Apa yang tergambar

Jumlah pelanggan untuk tiap pasangan segmen asal (per 2025-12-31, baris) dan segmen tujuan (per 2026-03-31, kolom), dalam orang.

Rentang data

5.000 pelanggan yang sama di kedua tanggal, dari tabel transaksi yang sama.

Yang terlihat

Di baris Loyal, kotak amber di kolom At Risk memuat 857 orang, sedangkan kotak At Risk ke At Risk hanya memuat 43.

Bantahan kedua atas temuan 2 Lolos setelah redaksi dikoreksi

"Rp 2,74 miliar itu nilai masa lalu. Kamu tidak tahu berapa yang kembali kalau mereka dirayu, dan berapa ongkos merayunya."

Bantahan ini benar seluruhnya, jadi jawabannya bukan membantah balik, melainkan mengoreksi redaksi temuan sampai bantahan itu tidak punya pintu masuk.

Redaksi yang tidak bertahan

"Win-back akan mengembalikan Rp 2,74 miliar yang hilang."

Redaksi yang dipakai

"Kelompok ini pernah rutin dan membawa Rp 2,74 miliar nilai historis. Berapa yang bisa dipulihkan belum diketahui; uji win-back dirancang untuk menjawabnya."

Temuannya tidak menjadi lebih lemah, ia berubah bentuk: dari klaim proyeksi menjadi klaim historis ditambah usulan eksperimen. Dari koreksi inilah lahir bentuk program win-back sebagai uji terukur dengan kelompok pembanding.

Bantahan atas pembersihan data Lolos

"2.400 duplikat yang kamu buang itu bisa jadi transaksi ganda yang sah. Jangan-jangan kamu menekan Frequency pelanggan terbaik."

Baris-baris itu identik termasuk TransactionID, dan dua pembelian sungguhan selalu tercatat dengan dua nomor berbeda. Pemeriksaannya dijalankan: 2.346 nomor transaksi muncul lebih dari sekali di data mentah, dan **nol** konflik tersisa setelah dedup. Tidak ada pasangan bernomor sama dengan nilai berbeda.

Bantahan yang tidak punya jawaban Diakui sebagai batas

"Seluruh analisis ini membaca masa lalu. Dari mana kamu tahu kuartal depan menyerupai lima kuartal terakhir?"

Tabel transaksi tidak memuat kuartal depan, jadi bantahan ini tidak bisa dijawab dengan kueri apa pun. Ia dinyatakan sebagai asumsi berikut mitigasinya: segmentasi dijalankan ulang tiap kuartal dengan pipeline dan jendela yang sama, dan pergeseran antar-kuartal menjadi sinyal paling awal bahwa pasarnya bergerak.

Keputusan

Pertanyaan rapat bergeser dari *berapa besar voucher yang dikirim ke semua orang* menjadi *kelompok mana yang anggarannya dipusatkan, dan atas dasar apa*. Anggaran yang sama kini membiayai dua program.

Program	Sasaran	Porsi	Per kepala
Apresiasi dan akses prioritas	400 Champions	Rp 90 juta	Rp 225.000
Uji win-back terukur	552 yang baru berhenti: 276 dikirim, 276 pembanding	Rp 50 juta	Rp 181.159 per orang yang dikirim
Cadangan pengukuran dan kanal	Lintas program	Rp 10 juta	Tidak berlaku

Bentuknya apresiasi dan akses, bukan diskon. Median 3 hari sejak transaksi terakhir menunjukkan kelompok teratas sudah aktif tanpa dibayar. Mengguyur diskon ke sana berarti membiayai perilaku yang sudah terjadi.

Sasaran win-back dipersempit dari 900 ke 552 orang. Kelompok ini berhenti paling belakangan, sejak Desember 2025, dan membawa Rp 1,70 miliar dari Rp 2,74 miliar nilai kelompoknya. Data ini tidak membuktikan mereka lebih mudah dipulihkan, karena tidak ada data respons yang bisa membuktikannya. Yang bisa dipertahankan hanya ini: di situlah taruhan terbesarnya duduk, jadi di situ pula uji berskala kecil memberi sinyal paling cepat.

276 dikirim
Menerima program senilai Rp 181.159 per orang

276 pembanding
Sengaja tidak dikirim apa pun selama Q2 2026

Sepuluhnya sengaja tidak dikirim apa pun. Sekitar 80% kelompok berprofil serupa historisnya bertransaksi lagi dalam satu kuartal tanpa program khusus. Tanpa pembanding, angka "berapa yang kembali" pasti terlihat bagus berapa pun efek programnya. Siapa yang dikirim ditentukan oleh hash yang deterministik atas CustomerID, bukan oleh pilihan siapa pun, dan kedua kelompok seimbang sebelum apa pun dikirim. Porsi ujinya sengaja kecil, karena skala Q3 2026 ditentukan oleh hasil uji ini, bukan oleh keyakinan hari ini.

Yang akan diukur

Rekomendasi ini belum punya hasil, jadi yang bisa saya nyatakan bukan hasilnya, melainkan cara mengetahuinya. Tiga ukuran ditetapkan sekarang, sebelum programnya jalan, supaya tidak dipilih belakangan agar terlihat bagus. Ketiganya dibaca pada 2026-06-30, akhir kuartal programnya.

Ukuran	Cara membacanya
Tingkat pembelian ulang 276 yang dikirim, dikurangi tingkat pembelian ulang 276 pembanding	Selisih inilah efek programnya. Dengan ukuran kelompok ini, hanya selisih sekitar 10 sampai 12 poin persen ke atas yang bisa dibedakan dari kebetulan
Berapa dari 400 Champions yang masih Champions per 2026-06-30, dengan jendela yang sama panjang	Deskriptif, bukan bukti efek, karena seluruh Champions menerima program. Patokannya, 81 dari 83 Champions per 2025-12-31 bertahan tiga bulan tanpa program apa pun
Biaya per tambahan pelanggan yang kembali	Rp 50 juta dibagi selisih jumlah yang kembali antara kedua kelompok. Angka ini yang menentukan apakah program layak diperbesar, dipertahankan, atau dihentikan

Batas dan telusur

- Seluruh angka menggambarkan perilaku sampai 2026-03-31.** Rekomendasinya mengasumsikan Q2 2026 menyerupai lima kuartal terakhir. Asumsi itu tidak bisa diuji dari data transaksi, dan karena itu segmentasi dijalankan ulang tiap kuartal dengan pipeline dan jendela 15 bulan yang sama.
- Rp 2,74 miliar adalah nilai historis, bukan proyeksi pemulihan.** Berapa yang bisa dipulihkan tidak diketahui. Justru itu alasan bentuk programnya uji terukur, bukan janji angka.
- Garis antar-segmen adalah keputusan analisis.** Menurunkan ambang frekuensi Loyal dua langkah memindahkan 824 pelanggan, dan menggeser garis 90 hari ke 105 memindahkan 354. Sementara itu, menaikkan ambang hari Champions 50% tidak memindahkan seorang pun. Di ketujuh geseran yang diuji, Champions tetap memegang 28,7% sampai 30,7% nilai, dan kelompok yang baru menjauh tetap ada (361 sampai 654 orang). Yang berubah ukurannya, bukan arah rekomendasinya.

Angka	Asalnya
48.130 transaksi bersih	Pipeline empat tahap atas tabel transaksi; jumlah tiap tahap tercatat
400 / 1.100 / 900 / 2.600	Agregasi per pelanggan dalam jendela 15 bulan, lalu klasifikasi ambang
28,7% dan 24,7% pangsa nilai	Jumlah nilai transaksi per segmen dibagi total Rp 11,10 miliar
49,2% di 20% teratas	Nilai kumulatif pelanggan, diurutkan dari yang terbesar belanjanya
857 dari 900; 850 dengan jendela sama	Segmentasi per 2025-12-31 digabungkan dengan segmentasi per 2026-03-31, per pelanggan
552 orang dan Rp 1,70 miliar	Segmen At Risk dipecah menurut jeda sejak transaksi terakhir
276 dikirim, 276 pembanding	Urutan hash MD5 atas CustomerID; daftar lengkap ada di notebook
Sekitar 80% kembali; batas deteksi 10 sampai 12 poin	184 dari 231 pelanggan berprofil sama pada tiga tanggal acuan sebelumnya; uji dua kelompok, alfa 0,05, daya 80%
824 dan 354 pelanggan berpindah	Ambang frekuensi Loyal digeser dari 8 ke 6, dan garis Recency dari 90 ke 105 hari
Rp 375.000, Rp 225.000, dan Rp 30.000 per orang	Aritmetika atas asumsi anggaran, bukan temuan dari data

Seluruh angka dihitung dari satu tabel transaksi 50.980 baris lewat kueri yang tercatat lengkap, dan tidak ada angka yang diketik dari gambar. Seluruh pembersihan, agregasi, dan perhitungan dikerjakan dengan SQL di DuckDB; Python hanya merender gambar. Kelima angka rujukan yang diserahkan bersama studi kasus cocok seluruhnya. Dua catatan naratif yang menyertainya tidak cocok dengan keluaran fungsi kuantil yang ditetapkan, dan selisihnya dicatat apa adanya alih-alih dipaksa cocok.

Berkas pendukung

Notebook analisis

Seluruh kueri SQL, uji kepekaan, uji bantahan, dan daftar penugasan uji win-back

Memo keputusan

Satu halaman untuk pemegang anggaran: rekomendasi, batas, syarat pembatal

Catatan keputusan

Setiap definisi, ambang, dan pilihan yang ditolak, berikut alasannya

Menjalankan ulang. Muat `transactions.csv`, jalankan [notebook analisis](#) apa adanya, lalu cocokkan jumlah tiap tahap pembersihan dengan 50.980, 48.580, 48.230, 48.180, dan 48.130. Tanggal acuan terkunci sebagai literal di dalam kueri, jadi hasilnya sama kapan pun notebook dijalankan.

Dibuat oleh **Aulia Aorama**. Kueri lengkap, uji kepekaan, dan daftar penugasan uji win-back tersedia di [notebook analisis](#), dengan ringkasannya di [memo keputusan](#) dan rincian setiap pilihan di [catatan keputusan](#). Data, notebook, dan seluruh berkas juga tersimpan di [repositori GitHub](#). Hubungi lewat aoramaaulia@gmail.com atau lihat proyek lain di [GitHub](#).

Anggaran Rp 150 juta, open rate 12%, dan redemption voucher 3% dikutip dari laporan campaign kuartal sebelumnya dan tidak diverifikasi dari tabel transaksi. Ketiganya dipakai sebagai konteks dan tidak menopang satu pun temuan di atas.